hackathon
GENERATIVE AI

Challenge proposé par

CISCO

Équipe 27 :

- Uriel Louis
- Alexandre Novais
- Rafik Bennacer
- David Ribeiro Caldeira

Lien git : https://github.com/AlexandreN8/hackaton

UNIVERSITE PARIS 8 DES CRÉATIONS

université PARIS-SACLAY

UQAC Université du Québec à Chicoutimi

Pertinence et innovation

1. Compréhension du cas d'usage et identification des besoins

L'explosion de l'Intelligence Artificielle Générative impose une transformation radicale des infrastructures technologiques. L'entraînement et l'inférence des modèles d'IA reposent sur des clusters de GPU à très haute densité (ex : AMD MI300X) dont la consommation électrique et la dissipation thermique dépassent largement les capacités des Data Centers traditionnels.

Le besoin métier est donc double :

- Économique et opérationnel : Prévenir les surchauffes (throttling) qui dégradent les performances et endommagent le matériel.
- Écologique : Maîtriser l'empreinte carbone et la consommation d'eau face au « mur énergétique » de l'IA, en passant d'un refroidissement classique par air (PUE de 1.5) à des solutions liquides (DLC ou Immersion Cooling avec un PUE proche de 1.05).

2. Pertinence de la solution proposée

Pour répondre à ce défi, notre équipe a conçu un **dashboard interactif** de monitoring thermique et environnemental en temps réel. Plutôt que de proposer une simple feuille de calcul statique, nous offrons aux différents opérateurs et décideurs (comme Cisco ou leurs clients) un outil d'aide à la décision dynamique.

La solution s'articule autour de deux modes complémentaires : un simulateur what-if permettant de comparer les 4 technologies à charge IT configurable (Air Cooling, RDHx, DLC, Immersion Cooling), et un dashboard temps réel alimenté par un pipeline Kafka qui observe les différences thermiques entre technologies sous workload identique. Dans les deux cas, chaque métrique physique est traduite en KPIs métiers (Coûts en €, Bilan Carbone, Consommation d'eau) avec sa formule et sa source académique.

3. Degré d'innovation et d'originalité

L'originalité de notre approche repose sur la création d'un modèle de simulation thermique représentatif des contraintes matérielles. Au lieu de générer des données de test aléatoires, notre système reproduit la véritable physique des baies serveurs. Par exemple, il illustre concrètement les limites du refroidissement par plaques froides (DLC) où le processeur est bien refroidi mais où l'alimentation continue de chauffer par rapport à l'efficacité globale de l'immersion (IC).

À cette base réaliste s'ajoute un moteur de recommandation multicritères configurable. Il pondère 5 critères métier (PUE, CO_2e, eau, densité rack, ROI) selon des profils contextuels sourcés comme Environnemental (GHG Protocol), Économique (Uptime Institute), Zone sèche (Green Grid). En changeant de profil, le classement des technologies évolue en temps réel, ce qui rend l'outil adaptable à chaque contexte client.

4. Anticipation des défis et adéquation opérationnelle

Notre solution a été pensée pour s'intégrer parfaitement aux attentes pratiques et quotidiennes du secteur. Sur le plan opérationnel, un gestionnaire de data center n'a pas besoin d'être noyé sous des flux de données brutes : il a besoin de lisibilité.
En transformant la télémétrie complexe en KPIs immédiatement actionnables (surcoût en euros, consommation d'eau, empreinte carbone, ROI), notre solution devient un véritable outil d'aide à la décision pour comparer objectivement les technologies de refroidissement.

De plus, la solution anticipe l'un des défis majeurs à venir : la densification extrême des serveurs IA. En affichant les formules et sources derrière chaque métrique (ASHRAE, GHG Protocol, EN 50600-4-6), l'outil permet de justifier les choix d'infrastructure avec des arguments sourcés plutôt qu'intuitifs ce qui est un atout clé pour les équipes de décision.

Qualité technique et faisabilité

1. Architecture logicielle et flux de données

Notre projet s'appuie sur un pipeline de données en temps réel, découpé en quatre briques distinctes. Cette séparation permet d'avoir un code lisible et facile à maintenir.

- **Génération des données (Producer) :** Un script Python simule en continu le comportement physique des baies serveurs. Il génère les différentes métriques matérielles (charge CPU/GPU, températures de la RAM, du processeur et des alimentations) en fonction de la technologie de refroidissement choisie.
- **Transmission des messages (Apache Kafka) :** Pour gérer ce flux d'informations en direct, nous avons mis en place des topics Kafka. Ce choix technique nous permet de centraliser les envois et garantit que le système restera stable et fluide même si l'on décide de simuler des dizaines ou des centaines de racks supplémentaires à l'avenir.
- **Traitement et calculs (Consumer / Backend) :** Un programme en arrière-plan vient lire les données stockées dans Kafka. C'est ici que s'applique la logique métier : le code utilise les constantes physiques (PUE, WUE) et les facteurs d'émission (gCO2/kWh) pour calculer l'empreinte environnementale et énergétique exacte de chaque serveur en temps réel.
- **Visualisation (Frontend) :** Une interface web conçue pour les utilisateurs métiers. Elle récupère les données calculées par le backend et affiche simplement l'évolution des températures et de l'impact carbone sous forme de graphiques et d'indicateurs de suivi.

2. Justification des choix technologiques

Le choix d'Apache Kafka se justifie par sa robustesse standard dans l'industrie pour la lecture de données massives. Le recours à un jeu de données pré-généré (Dataset JSONL) projeté dans le futur a permis de valider le pipeline Data en condition de stress réel, tout en garantissant une démonstration fluide.

De plus, la structuration du payload a été standardisée avec un champ "source", permettant de passer d'une simulation à de véritables capteurs physiques sans modifier une seule ligne de code du Backend.

Enfin, sur le plan méthodologique, nous avons privilégié une approche modulaire. Le code source fourni dans notre dépôt Git est strictement documenté, séparant clairement les responsabilités (Producer, Consumer, Frontend) afin de garantir une lisibilité optimale et une reprise facile du projet.

3. Implémentation de l'IA et réalisme à grande échelle

Notre contribution IA repose sur un moteur de recommandation multicritères configurable. Concrètement, le score composite pondère 5 critères métier selon 4 profils contextuels sourcés (Environnemental, Économique, Zone sèche, Haute densité). En changeant de profil, le classement des technologies change en temps réel. Un service de recommandation LLM (/stream-reco) est architecturé pour générer une analyse argumentée depuis les résultats du calculateur, mais n'a pas pu être implémenté dans le temps du hackathon.

Sur le plan de l'architecture logicielle, le système a été pensé pour un déploiement massif. L'intégration de nouvelles baies serveurs nécessite uniquement de déclarer un nouvel identifiant (rack_id) dans le flux de données entrant. Le backend s'adapte automatiquement à ce nouveau flux sans nécessiter de refonte du code, ce qui valide pleinement la faisabilité opérationnelle de la solution à l'échelle d'un véritable data center.

Impact, risques et responsabilité

1. Analyse des impacts (Écologiques et Financiers)

L'impact positif de notre solution est massif. En rendant visible ce qui était autrefois invisible, notre dashboard permet aux entreprises d'optimiser leurs infrastructures. À grande échelle, le passage d'un Data Center IA de l'Air Cooling vers l'Immersion Cooling, motivé par les prédictions de notre outil, permet :

- Une réduction de plus de 30% de la facture énergétique liée au refroidissement.
- L'éradication de la consommation d'eau potable (le WUE passant de 1.8 L/kWh à 0 L/kWh en Immersion).
- Une prolongation de la durée de vie du matériel (GPU/CPU) grâce à l'évitement des chocs thermiques.

Sur le plan réglementaire, cet outil facilite également la mise en conformité des opérateurs avec la nouvelle Directive Européenne sur l'Efficacité Énergétique (EED), qui impose un reporting strict du PUE et du WUE des data centers.

2. Identification des risques et limites

Toutefois, le déploiement d'une telle solution en milieu industriel comporte des risques qu'il faut maîtriser :

- Biais du modèle de recommandation : Les pondérations des profils (Environnemental, Économique, etc.) sont des hypothèses documentées, non des vérités universelles. Un client avec des contraintes spécifiques peut obtenir un classement différent. Mesure : les poids sont transparents, configurables et sourcés dans l'interface.
- **Dépendance technologique :** La confiance aveugle dans le tableau de bord numérique peut réduire la vigilance physique des opérateurs sur site.
- **Cybersécurité :** Centraliser les données de performance du matériel IA expose le système à des risques d'espionnage industriel ou d'attaques par déni de service (DDoS) sur le cluster Kafka.

De plus, il convient de reconnaître les limites actuelles de notre preuve de concept : notre moteur de recommandation repose sur des constantes de référentiel (PUE/WUE typiques) et non sur des mesures capteurs réelles, et la brique d'analyse textuelle par IA générative (endpoint /stream-reco) a été volontairement exclue du périmètre de ce PoC pour nous concentrer sur la fiabilité des calculs thermodynamiques.

3. Mesures de mitigation et responsabilité

Pour limiter ces risques, la solution doit intégrer le principe du « Human in the loop » (L'humain dans la boucle). Les recommandations du moteur multicritères sont des aides à la décision, non des décisions automatiques. Les actions critiques (changement de technologie, arbitrages budgétaires) doivent être validées par un opérateur. De plus, les flux Kafka doivent être chiffrés de bout en bout et isolés sur un réseau de management dédié (VLAN) pour garantir l'intégrité et la sécurité des données télémétriques.

Enfin, le déploiement de cet outil nécessitera une formation spécifique des équipes de maintenance, afin qu'elles comprennent la logique du score composite et restent critiques face aux recommandations de l'outil.

Conclusion et recommandations

1. Synthèse des apports du projet

Durant ce hackathon, notre équipe a prouvé qu'il était possible de conjuguer la haute performance exigée par l'Intelligence Artificielle Générative avec les impératifs de la transition écologique. En croisant l'ingénierie des données (Data Engineering avec Kafka), la logique métier (simulation fidèle des contraintes matérielles) et un moteur de recommandation multicritères configurable, nous avons livré une solution de bout en bout, fonctionnelle et crédible. Le produit développé démontre que l'Immersion Cooling et le Direct Liquid Cooling ne sont plus de simples concepts de R&D, mais des nécessités absolues pour l'avenir de la tech.

2. Limites principales

Dans le cadre contraint de cet exercice, la solution présente naturellement certaines limites. Le jeu de données utilisé reste une simulation, bien que physiquement réaliste.

De plus, le service de recommandation LLM (/stream-reco) est architecturé mais non implémenté dans ce PoC, faute de temps. Les constantes du référentiel (PUE, WUE, CAPEX) sont des valeurs typiques sourcées, non des mesures terrain contractuelles.

3. Perspectives d'évolution et recommandations

Pour passer d'un Proof of Concept (PoC) à un produit déployable chez un client, notre feuille de route s'articule autour de recommandations immédiates et de perspectives d'évolution plus larges :

- **Recommandation technique (À court terme) - Hardware In the Loop (HIL) :** Nous recommandons de remplacer notre script de simulation par les API de vrais capteurs IoT branchés sur des serveurs physiques, afin de valider le comportement du pipeline Data en conditions réelles.
- **Remplacement du producer simulé (À court terme) :** Remplacer le script producer Python par un broker MQTT (ex : Mosquitto) branché sur les capteurs IPMI/Redfish des serveurs physiques Cisco. MQTT est le protocole standard pour la télémétrie IoT.
- **Orchestration des flux de données (À moyen terme) :** Intégrer Apache NiFi en amont de Kafka pour ingérer des sources hétérogènes (IPMI, SNMP, Redfish API, Cisco Intersight) et les normaliser dans un payload unifié avant traitement. NiFi apporte la robustesse et la supervision des flux nécessaires pour un déploiement à l'échelle d'un vrai datacenter multi-racks.
- **Perspective d'évolution fonctionnelle (À moyen terme) - Automatisation active :** La solution a vocation à évoluer en se connectant aux orchestrateurs de conteneurs (ex : Kubernetes). Si **le modèle prédictif** anticipe une surchauffe imminente sur un rack, le système migrerait automatiquement les calculs vers les racks froids les plus efficaces (Load Balancing thermique).
- **Perspective d'évolution métier (À moyen terme) - Analyse de cycle de vie (ACV) :** L'outil pourra intégrer le coût carbone lié à la fabrication du liquide d'immersion et du matériel informatique, offrant ainsi un bilan écologique complet (Scope 1, 2 et 3).